

Modelado dinámico de degradación de motores de aviones Turbofan mediante UDEs

Gian Lucca Sanza y Sebastian Souto

1 Introducción

La detección temprana de fallas en motores aeronáuticos constituye un problema de gran importancia para la industria aeroespacial. La capacidad de anticipar el deterioro de un motor permite planificar tareas de mantenimiento de manera más eficiente, reducir costos operativos y, fundamentalmente, garantizar condiciones seguras de funcionamiento. En este contexto, el mantenimiento predictivo busca aprovechar la información generada durante la operación de los equipos para estimar su estado de salud y anticipar posibles fallas antes de que estas ocurran.

Los motores modernos se encuentran equipados con numerosos sensores que registran variables asociadas a su desempeño, tales como temperaturas, presiones y velocidades de rotación. Estas mediciones generan series temporales que contienen información sobre la evolución del sistema y los procesos de degradación que experimenta a lo largo de su vida útil. El desafío consiste en transformar estas observaciones en modelos capaces de describir la dinámica de degradación y producir predicciones confiables sobre el comportamiento futuro del motor.




Figure 1: Esquema conceptual de sensores en un motor turbofan.

Para este trabajo se utiliza el conjunto de datos C-MAPSS (Commercial Modular Aero-Propulsion System Simulation), desarrollado por la NASA [1]. Este dataset contiene trayectorias simuladas de motores turbofan operando bajo diferentes condiciones y modos de falla. Cada trayectoria

está compuesta por múltiples ciclos de operación, junto con mediciones de sensores y variables operativas que reflejan el estado interno del motor. Debido a que las trayectorias finalizan en la falla del sistema, el conjunto de datos constituye un entorno adecuado para estudiar procesos de degradación progresiva y desarrollar modelos de mantenimiento predictivo.

El objetivo de este trabajo es desarrollar un modelo capaz de estimar la probabilidad de falla de un motor en cada ciclo de operación a partir de las mediciones de sensores disponibles y para ello se adopta un enfoque basado en análisis de supervivencia. En lugar de construir probabilidades de falla a partir del Remaining Useful Life (RUL), se modela directamente el proceso de ocurrencia de la falla a lo largo del tiempo. De esta manera, las probabilidades estimadas surgen de una formulación probabilística consistente con las observaciones disponibles y pueden interpretarse naturalmente en términos de riesgo de falla.

Para describir la evolución temporal del sistema se utilizan modelos dinámicos basados en Neural Ordinary Differential Equations (NODEs) [2] y Universal Differential Equations (UDEs) [3]. Estos enfoques combinan herramientas provenientes de las ecuaciones diferenciales con técnicas modernas de aprendizaje automático, permitiendo representar dinámicas complejas incluso cuando las leyes físicas subyacentes no son completamente conocidas. Esta combinación resulta especialmente atractiva en problemas de degradación, donde existe conocimiento parcial sobre los mecanismos involucrados pero no se dispone de un modelo físico completo del sistema.

Se analiza cómo distintas decisiones de modelado afectan el comportamiento predictivo del sistema y su utilidad práctica para tareas de mantenimiento predictivo. En particular, se estudia el compromiso entre detectar fallas de manera temprana, favoreciendo la seguridad operacional, y extender el tiempo de utilización del motor, maximizando el aprovechamiento de su vida útil.

2 Métodos

2.1 Dataset

Como se mencionó anteriormente para este trabajo se utiliza el conjunto de datos C-MAPSS , desarrollado por la NASA para el estudio de estrategias de mantenimiento predictivo. El dataset contiene múltiples trayectorias simuladas de motores turbofan sometidos a procesos de degradación progresiva hasta la falla.

Los datos se encuentran organizados en tres tipos de archivos:

- Train: contienen trayectorias completas de distintos motores, desde el inicio de su operación hasta el instante de falla.
- Test: contienen trayectorias truncadas, es decir, observaciones de motores que aún no han alcanzado la falla dentro de los datos disponibles.
- RUL: contienen el Remaining Useful Life (RUL) asociado a cada trayectoria del conjunto de test, indicando la cantidad de ciclos restantes hasta la falla.

En este trabajo se utilizan exclusivamente las trayectorias del conjunto de entrenamiento. Dado que cada una de ellas finaliza en la falla del motor, es posible formular el problema como uno de

supervivencia discreta utilizando directamente los tiempos observados de falla.

2.2 Formulación del problema

El objetivo consiste en estimar la probabilidad de falla de un motor en cada ciclo de operación a partir de las mediciones de sensores y condiciones operativas disponibles.

Para ello, se define para cada instante temporal (t) de una trayectoria la variable objetivo

$$y_t = \begin{cases} 1 & \text{si el motor falla en el ciclo } t \\ 0 & \text{caso contrario} \end{cases}$$

Dado que todas las trayectorias del conjunto de entrenamiento finalizan en la falla, la última observación de cada motor recibe la etiqueta 1, mientras que todas las observaciones previas reciben la etiqueta 0.

Esta formulación permite abordar el problema desde la perspectiva del análisis de supervivencia, donde el interés principal radica en modelar la ocurrencia de la falla a lo largo del tiempo [4].

2.3 Modelo dinámico

La evolución temporal del sistema se modela mediante un estado latente ($z(t)$) gobernado por una ecuación diferencial ordinaria de la forma

$$\frac{dz}{dt} = f_\theta(z(t), x(t))$$

donde ($x(t)$) representa las mediciones de sensores y las condiciones operativas observadas en el instante (t), mientras que (f_θ) corresponde a una función parametrizada mediante una red neuronal.

A partir del estado latente se obtiene una estimación de riesgo mediante una capa de salida sigmoideal

$$h_t = \sigma(z_t)$$

La cantidad (h_t) se interpreta como la probabilidad de que el motor falle en el ciclo (t), condicionada a haber sobrevivido hasta el ciclo anterior.

Dependiendo de la elección de la dinámica (f_θ), se obtienen distintas variantes del modelo. En particular, se consideran Neural Ordinary Differential Equations (NODEs) y Universal Differential Equations (UDEs), cuyos detalles se describen en las secciones siguientes.

2.4 Entrenamiento mediante supervivencia discreta

Los parámetros del modelo se estiman mediante máxima verosimilitud. Para una trayectoria que falla en el ciclo (T), la probabilidad de observar dicha trayectoria está dada por

$$P(T) = \left(\prod_{t=1}^{T-1} (1 - h_t) \right) h_T$$

La expresión anterior refleja que el motor debe sobrevivir durante los primeros $(T-1)$ ciclos y fallar exactamente en el ciclo (T) .

Equivalentemente, el entrenamiento se realiza minimizando la log-verosimilitud negativa

$$\mathcal{L} = - \sum_{t=1}^{T-1} \log(1 - h_t) - \log(h_T) \quad (1)$$

Esta formulación permite obtener probabilidades de falla directamente a partir de los tiempos observados de falla, evitando la necesidad de construir etiquetas probabilísticas artificiales a partir del Remaining Useful Life.

2.5 Desbalance de clases

Una característica relevante de esta formulación es la presencia de un fuerte desbalance de clases. En particular, para cada trayectoria la mayoría de las observaciones corresponden a la clase $(y_t = 0)$, mientras que únicamente una observación por motor corresponde a la clase positiva $(y_t = 1)$. Este desbalance puede dificultar el aprendizaje de la dinámica de falla y afectar la estabilidad del entrenamiento.

Para mitigar este problema, se introduce una variante basada en un horizonte de falla (H) . En este esquema, la variable objetivo se redefine como

$$y_t^{(H)} = \begin{cases} 1 & \text{si faltan } \leq H \text{ ciclos para la falla} \\ 0 & \text{caso contrario} \end{cases}$$

Esta reformulación amplía la región temporal considerada como evento de interés, reduciendo el desbalance extremo presente en la formulación original.

Otro método que se va a implementar para contrarrestar el desbalance de clases, es asignarle pesos a la función de pérdida. Esta técnica consiste en multiplicar los términos de (1) por pesos w_i , tal que se le de mayor "relevancia" al error cometido en el ciclo de falla.

Los valores de w_i se seleccionaron mediante una división interna del conjunto de entrenamiento: se entrenaron modelos con distintos valores candidatos y se evaluaron sobre un subconjunto de validación. Una vez seleccionado el valor, el modelo final se reentrenó utilizando todas las trayectorias de entrenamiento y se evaluó una única vez sobre el conjunto de prueba.

Ambas definiciones de la variable objetivo —la etiqueta exacta asociada al instante de falla y la versión con horizonte— son utilizadas para el entrenamiento y la evaluación de los modelos, con el objetivo de analizar el impacto de esta modificación sobre el desempeño predictivo.

2.6 Modelos

Se pusieron a prueba diferentes modelos, tanto UDEs como NODEs. A continuación los enumeramos:

$$\frac{dz}{dt} = -\alpha z + NN(z, \tau, S(t)) \quad (2)$$

En (2), se plantea una UDE con termino físico $-\alpha z$. Para este modelo se probaron los siguientes métodos:

- Entrenamiento con horizonte
- Entrenamiento con variable objetivo exacta
- Entrenamiento con horizonte + α entrenable
- Entrenamiento con horizonte + términos de regularización

$$\frac{dz}{dt} = softplus(NN(\tau, S(t))) \quad (3)$$

En (3), se plantea una NODE donde $z(t)$ es monótono creciente y la degradación solo puede acumularse. Este modelo es mucho más interpretable. Y se probó el siguiente método:

- Entrenamiento con horizonte

$$\frac{dz}{dt} = -\alpha z + softplus(NN(\tau, S(t))) \quad (4)$$

En (4) se plantea una UDE. A simple vista parece igual a (2) pero la diferencia es que la red neuronal no tiene como input z . Por lo tanto, se puede interpretar de la siguiente manera: $-\alpha z$ modela la relajación/memoria del sistema y $softplus(NN(\tau, S(t)))$ representa una tasa de degradación no negativa. Para este modelo se probó el siguiente método:

- Entrenamiento con horizonte

2.7 Regularización de la trayectoria predicha

En algunos experimentos se observaron oscilaciones locales y picos abruptos en la trayectoria de probabilidad estimada. Dado que la degradación de un motor es un proceso progresivo, resulta razonable incorporar términos de regularización que favorezcan predicciones más suaves.

Se agregó una penalización sobre la curvatura discreta de la predicción:

$$\frac{1}{T-2} \sum_{t=2}^{T-1} (h_{t+1} - 2h_t + h_{t-1})^2$$

La función de pérdida total queda dada por

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{BCE}} + \lambda_{\text{curv}} \mathcal{L}_{\text{curv}}$$

2.8 Selección de sensores

El conjunto de datos C-MAPSS contiene 21 sensores que registran variables físicas asociadas al funcionamiento del motor. Incluir todas las variables en el modelo implica un mayor costo computacional y puede introducir redundancia debido a la presencia de sensores altamente correlacionados o no informativos.

Con el objetivo de reducir la dimensionalidad de la entrada y mejorar la calidad de las variables utilizadas, se realizó un proceso de selección de sensores basado en tres criterios complementarios.

En primer lugar, se eliminaron aquellos sensores que presentan varianza nula o casi nula a lo largo de todas las trayectorias. Estos sensores no aportan información discriminativa sobre el proceso de degradación, ya que permanecen constantes independientemente del estado del motor.

En segundo lugar, se evaluó la relación entre cada sensor y el Remaining Useful Life (RUL) mediante el coeficiente de correlación de Pearson. Este análisis permite identificar sensores cuyo comportamiento está asociado al proceso de degradación, ya sea de forma positiva o negativa, priorizando aquellos con mayor valor absoluto de correlación.

Finalmente, se analizó la correlación entre sensores con el objetivo de evitar redundancia en la información. En particular, se buscó descartar conjuntos de variables altamente correlacionadas entre sí, conservando únicamente aquellas que aportan información complementaria sobre la dinámica del sistema.

Como resultado de este procedimiento, se seleccionaron los cinco sensores más relevantes según los criterios anteriores, los cuales fueron utilizados como entrada en los modelos desarrollados.

2.9 Entrenamiento con mini-batches

Con el objetivo de mejorar la eficiencia computacional del entrenamiento, se utilizó un esquema de optimización basado en mini-batches [5]. En lugar de calcular la función de pérdida utilizando la totalidad de las trayectorias del conjunto de entrenamiento en cada iteración, los datos se dividen en subconjuntos (batches), sobre los cuales se estima una aproximación de la pérdida total.

La utilización de mini-batches permite reducir significativamente el costo computacional por iteración, acelerando el proceso de entrenamiento sin modificar la formulación de la función de pérdida. En el caso de este trabajo, este enfoque resultó en una reducción sustancial del tiempo de entrenamiento, pasando de un esquema de entrenamiento completo a un régimen de optimización más eficiente, manteniendo un desempeño comparable en términos de convergencia.

2.10 Regresión Logística

Además de los modelos basados en ecuaciones diferenciales neuronales (NODE) y ecuaciones diferenciales universales (UDE), se consideró un enfoque clásico de aprendizaje supervisado mediante regresión logística.

El objetivo de este experimento es contar con una línea base sencilla que permita evaluar si la complejidad adicional introducida por los modelos dinámicos se traduce efectivamente en una mejora en la capacidad de detección de fallas.

Para cada instante temporal de una trayectoria se construyó un vector de características compuesto por las mediciones de los sensores seleccionados y una variable temporal normalizada. A partir de estas variables, la regresión logística estima la probabilidad de que el motor falle.

Matemáticamente, el modelo estima

$$P(Y = 1 | X) = \sigma(\beta_0 + \beta^T X),$$

donde X representa el vector de características, β son los parámetros a estimar y $\sigma(\cdot)$ es la función sigmoide

$$\sigma(x) = \frac{1}{1 + e^{-x}}.$$

Una vez obtenidas las probabilidades predichas, se define un umbral de decisión para determinar el primer ciclo en el que el modelo detecta una falla inminente.

2.11 Criterio de evaluación comparativa

Para comparar los modelos se analizó la trayectoria de probabilidad de falla estimada para cada motor. A partir de dicha trayectoria, se definió un ciclo predicho de falla como el primer ciclo en el cual la probabilidad estimada supera un umbral de decisión η :

$$\hat{T} = \min\{t : h_t \geq \eta\}.$$

En este trabajo se utilizó $\eta = 0.989$. Este umbral no forma parte del entrenamiento de los modelos, sino que se utiliza únicamente como criterio de evaluación para transformar la trayectoria continua de probabilidades en una detección puntual. De esta manera, todos los modelos evaluados pueden compararse bajo una misma regla de decisión, independientemente de si fueron entrenados con etiqueta exacta de falla o con una etiqueta basada en horizonte.

El ciclo predicho $\hat{T}$ se compara con el ciclo real de falla T , definido como el último ciclo observado de cada trayectoria. A partir de esta comparación se calcula el error temporal:

$$\Delta T = \hat{T} - T.$$

Un valor negativo de ΔT indica que el modelo anticipa la falla, mientras que un valor igual a cero indica una detección exacta en el ciclo final observado. Si la trayectoria de probabilidad no supera el umbral η , se considera que el modelo no detecta la falla para ese motor.

Sobre las trayectorias efectivamente detectadas se calculan el error medio, el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE). Además, se reporta la tasa de detección, definida como la proporción de motores para los cuales la trayectoria predicha supera el umbral al menos una vez. También se informa la proporción de detecciones tempranas y exactas, calculadas sobre el conjunto de trayectorias detectadas.

Cabe distinguir este criterio de evaluación del uso del horizonte H durante el entrenamiento. El horizonte modifica la definición de la variable objetivo, asignando etiqueta positiva a los ciclos cercanos a la falla. En cambio, el umbral η se aplica posteriormente sobre las probabilidades predichas para determinar en qué ciclo el modelo emitiría una alerta.

3 Resultados

3.1 Ejemplos de predicción de falla




Figure 2: Probabilidad de falla estimada para un motor del conjunto de prueba. Se muestran la predicción del modelo, la etiqueta con horizonte de falla y el instante de falla real.




Figure 3: Trayectorias de probabilidad obtenidas para un mismo motor utilizando las distintas variantes de modelo evaluadas.

3.2 Resultados comparativos por modelo

Modelo	Det.	Error medio	RMSE	Varianza	Tempranas	Exactas
UDE horizonte	66.67%	-3.38	4.40	9.12	75.00%	25.00%
UDE exacta	83.33%	-6.5	8.34	30.28	100.00%	0.00%
UDE α	66.67%	-3.63	4.49	7.98	87.50%	12.50%
UDE horizonte reg.	41.67%	-3.80	4.54	7.70	100.00%	0.00%
NODE acumulativa	75.00%	-9.11	13.81	121.11	77.78%	22.22%
UDE combinada	66.67%	-4.38	5.47	12.27	87.50%	12.50%
Regresión Log.	16.67%	-2.50	2.55	0.50	100.00%	0.00%

Table 1: Resumen comparativo de las métricas de evaluación para los modelos analizados. La columna Det. indica la tasa de detección. Las columnas Tempranas y Exactas se calculan únicamente sobre las trayectorias detectadas.

3.3 Resultados individuales por trayectoria

Además de la comparación general entre modelos, se registraron los resultados individuales por motor. Para cada trayectoria se informa el ciclo real de falla y la diferencia entre el ciclo predicho y el ciclo real de falla. Los valores negativos indican que la detección ocurrió antes del ciclo real de falla. Los casos indicados con “—” corresponden a trayectorias en las que el modelo no superó el umbral de decisión utilizado.

Motor	Real	Horizon	Exacta	α entrenable	Horizon reg.	NODE	Comb.	Regresión Log
1	215	-8	-11	-8	-7	-16	-6	—
2	198	-2	-4	-3	-1	-4	-1	—
3	213	—	—	—	—	—	—	—
4	213	-7	-12	-7	-6	-12	-7	—
5	195	0	-2	0	—	0	-2	—
6	257	—	—	—	—	-5	—	—
7	193	-3	-1	-3	—	—	0	—
8	275	—	-18	—	—	-35	—	—
9	137	-2	-4	-2	-1	0	-9	-3
10	147	—	-2	—	—	—	-2	—
11	231	-5	-7	-5	-4	-5	—	-2
12	172	0	-4	-1	—	-5	-8	—

Table 2: Diferencia entre el ciclo de detección predicho y el ciclo real de falla para los distintos métodos. Los guiones indican que el modelo no superó el umbral de detección para ese motor.

4 Discusión y conclusiones

4.1 Análisis cualitativo y cuantitativo de las trayectorias

Observando los resultados obtenidos en la Tabla 1, se puede concluir que el enfoque de supervivencia permite estimar la probabilidad de falla de un motor a lo largo del tiempo a partir de observaciones binarias de falla. En lugar de limitarse a predecir si un motor fallará o no, el modelo produce una trayectoria de riesgo que evoluciona con los ciclos de operación.

Esta estimación surge del modelado dinámico de la variable latente z , interpretada como una representación del estado de degradación del motor. Los resultados sugieren que esta formulación permite capturar información relevante sobre la evolución temporal del sistema y relacionarla con el riesgo de falla.

En términos de desempeño, las distintas variantes de UDE obtuvieron comportamientos diferentes. Los modelos entrenados mediante el enfoque de horizonte (UDE horizonte, UDE α y UDE horizonte regularizada) presentaron tasas de detección entre 41.67% y 66.67%, mientras que la UDE entrenada con la variable objetivo exacta alcanzó una tasa de detección de 83.33%.

Sin embargo, este incremento en la capacidad de detección estuvo acompañado por un aumento del error medio de predicción. En particular, la UDE exacta detectó una mayor proporción de fallas, pero tendió a anticiparlas con más ciclos de antelación que las variantes entrenadas con horizonte.

El modelo NODE acumulativo presenta una interpretación más directa desde el punto de vista de la dinámica de degradación, debido a que impone una derivada no negativa mediante la función *softplus*. Esta restricción obliga a que el estado de degradación evolucione de manera monótona creciente, lo cual resulta consistente con la hipótesis de un deterioro progresivo del motor. Como consecuencia, las trayectorias predichas por este modelo tienden a ser más regulares y evitan descensos abruptos en la probabilidad estimada de falla.

No obstante, esta mayor interpretabilidad cualitativa no se corresponde necesariamente con un mejor desempeño cuantitativo. De acuerdo con la tabla comparativa, la NODE acumulativa no presenta mayor tasa de detección significativa pero sí una mayor anticipación temporal respecto de otros

modelos. Esto indica que la restricción de monotonía, aunque adecuada desde una perspectiva física, puede limitar la flexibilidad del modelo para representar ciertos patrones presentes en los datos.

La UDE combinada introduce una estructura intermedia entre la UDE general y la NODE acumulativa. En esta formulación, el término $-\alpha z$ representa un efecto de relajación o memoria del sistema, mientras que el término $\text{softplus}(NN(\tau, S(t)))$ modela una tasa de degradación no negativa. Sin embargo, los resultados obtenidos no muestran una mejora sustancial respecto de los modelos mencionados anteriormente. La UDE combinada constituye una variante metodológicamente relevante, aunque no se identifica como el modelo de mejor desempeño en los experimentos realizados.

En conjunto, los resultados indican que la UDE exacta presenta el compromiso más equilibrado entre tasa de detección y error temporal dentro de los modelos evaluados. Esta variante logra detectar una proporción alta de trayectorias sin anticipar la falla de manera tan marcada como ocurre en otros enfoques.

Desde una perspectiva práctica, este comportamiento resulta relevante porque el objetivo del modelo no es únicamente detectar la falla, sino hacerlo en un intervalo temporal útil para la toma de decisiones. Una detección excesivamente temprana puede conducir a una subutilización del motor, mientras que una detección tardía reduce el margen disponible para planificar tareas de mantenimiento.

No obstante, esta conclusión debe interpretarse en el marco de las condiciones experimentales consideradas. La selección manual de pesos, el umbral de decisión utilizado y el subconjunto de motores evaluado pueden influir en la comparación entre modelos.

Finalmente se compararon los modelos basados en NODEs y UDEs con un enfoque clásico de clasificación mediante regresión logística. Los resultados de la Tabla 1 muestran que la regresión logística alcanza una tasa de detección del 16.66%, significativamente inferior a la obtenida por los modelos dinámicos considerados previamente.

Estos resultados sugieren que la complejidad adicional de los modelos NODE y UDE se encuentra justificada en este problema. A diferencia de la regresión logística, que realiza predicciones a partir de las observaciones disponibles en cada instante de forma independiente, estos modelos incorporan explícitamente la dinámica temporal del proceso de degradación mediante ecuaciones diferenciales. Esto les permite capturar la evolución del estado del motor a lo largo del tiempo y representar patrones más complejos asociados a la falla, lo que podría explicar su mejor desempeño en la detección temprana.

4.2 Posibles trabajos futuros

Como posibles trabajos futuros se propone evaluar arquitecturas más complejas. En este trabajo se utilizaron redes neuronales de una única capa oculta tanto para las NODEs como para las UDEs. Una posible extensión consiste en aumentar la profundidad y el número de parámetros de las redes para analizar si esto permite capturar con mayor precisión las dinámicas de degradación observadas en los motores.

Asimismo, resulta de interés explorar formulaciones alternativas de las UDEs mediante la incorporación de términos físicos más elaborados. En este trabajo se utilizaron modelos físicos simples

con el objetivo de estudiar la viabilidad del enfoque híbrido, pero podrían diseñarse ecuaciones que representen de manera más fiel los mecanismos de degradación de un motor turbofan.

Finalmente, dado que el dataset C-MAPSS está compuesto por trayectorias simuladas, sería de gran interés validar los modelos desarrollados sobre datos reales de operación.

5 Agradecimientos y uso de IA

Los autores agradecen al profesor Facundo Sapienza por su acompañamiento, sugerencias y correcciones durante el desarrollo de este trabajo, las cuales contribuyeron significativamente a mejorar tanto la formulación del problema como el análisis de los resultados.

Se utilizó ChatGPT (OpenAI) como herramienta de apoyo para la revisión y mejora de la redacción del informe. También se utilizó dicha herramienta para completar y generar fragmentos de código repetitivo. Todos los resultados, ecuaciones y conclusiones fueron verificados por los autores.

6 Datos y Software

Se utilizó el conjunto de datos C-MAPSS, desarrollado por la NASA, compuesto por trayectorias simuladas de motores turbofan bajo procesos de degradación progresiva.

La implementación experimental se realizó en Julia. Se utilizaron librerías orientadas al manejo de datos, modelado diferencial y optimización, incluyendo CSV, DataFrames, Statistics, Plots, Lux, ComponentArrays, OrdinaryDiffEq, SciMLSensitivity, Optimization, OptimizationOptimisers, Zygote, DataInterpolations, MLUtils y LinearAlgebra.

El código desarrollado para este proyecto está disponible en el Repositorio del proyecto bajo licencia MIT.

Referencias

- [1] A. Saxena and K. Goebel. *Turbofan Engine Degradation Simulation Data Set*. NASA Ames Prognostics Data Repository, NASA Ames Research Center, Moffett Field, CA, 2008.
- [2] R. T. Q. Chen, Y. Rubanova, J. Bettencourt and D. K. Duvenaud. *Neural Ordinary Differential Equations*. Advances in Neural Information Processing Systems 31, 2018.
- [3] C. Rackauckas, Y. Ma, J. Martensen, C. Warner, K. Zubov, R. Supekar, D. Skinner, A. Ramadhan and A. Edelman. *Universal Differential Equations for Scientific Machine Learning*. arXiv:2001.04385, 2020.
- [4] D. G. Kleinbaum and M. Klein. *Survival Analysis: A Self-Learning Text*. 2nd edition, Springer, 2005.
- [5] I. Goodfellow, Y. Bengio and A. Courville. *Deep Learning*. MIT Press, 2016.