

Modelado dinámico de degradación de motores Turbofan mediante NODEs y UDEs


Gian Lucca Sanza y Sebastian Souto

Datos, Ecuaciones Diferenciales e Inteligencia Artificial. Facultad de Ciencias Exactas y Naturales, UBA

Introducción

La detección temprana de fallas en motores aeronáuticos es un problema de gran importancia para la industria aeroespacial, ya que permite planificar tareas de mantenimiento, reducir costos operativos y mejorar la seguridad de las aeronaves.

Los motores modernos generan grandes volúmenes de información a través de sensores que registran variables como temperaturas, presiones, velocidades de rotación y otros indicadores asociados al funcionamiento interno del motor. Estas mediciones permiten construir trayectorias temporales que contienen información sobre el estado de salud del sistema y su proceso de degradación.



Esquema conceptual de sensores en un motor turbofan. Las mediciones temporales se utilizan para estimar la probabilidad de falla.

En este trabajo se utiliza el dataset C-MAPSS de la NASA, que contiene trayectorias simuladas de motores turbofan sometidos a distintos mecanismos de degradación hasta la falla.

El objetivo será estimar la probabilidad de falla de un motor a partir del modelado dinámico de su degradación mediante NODEs y UDEs.

Métodos

Formulación del problema. Para cada ciclo de operación se define una variable binaria que indica si el motor falla o continúa funcionando. Como cada trayectoria contiene una única falla, el problema presenta un fuerte desbalance de clases. Para mitigarlo, se evaluó también una formulación con horizonte de falla H , donde los ciclos cercanos a la falla se consideran positivos.

Modelo dinámico. La degradación se representa mediante un estado latente $z(t)$, cuya evolución depende de las mediciones de sensores $x(t)$:

$$\frac{dz}{dt} = f_{\theta}(z(t), x(t)), \quad h_t = \sigma(z_t).$$

La cantidad h_t se interpreta como la probabilidad estimada de falla en el ciclo t .

Entrenamiento. Para una trayectoria que falla en el ciclo T , el modelo asigna probabilidad

$$P(T) = \left(\prod_{t=1}^{T-1} (1 - h_t) \right) h_T.$$

Los parámetros se ajustan maximizando esta cantidad, o equivalentemente, minimizando la log-verosimilitud negativa:

$$\mathcal{L} = - \sum_{t=1}^{T-1} \log(1 - h_t) - \log(h_T).$$

Modelos evaluados. Se compararon tres familias de modelos:

UDE: $\frac{dz}{dt} = -\alpha z + NN(z, \tau, S(t)).$

NODE acumulativa: $\frac{dz}{dt} = \text{softplus}(NN(\tau, S(t))).$


UDE combinada: $\frac{dz}{dt} = -\alpha z + \text{softplus}(NN(\tau, S(t))).$

La NODE acumulativa impone una tasa de degradación no negativa, mientras que las UDEs incorporan un término físico junto con una componente neuronal.


Selección de sensores. El dataset C-MAPSS contiene 21 sensores asociados al funcionamiento del motor. Para reducir la dimensionalidad de entrada se seleccionaron sensores a partir de tres criterios: varianza no nula, correlación con el Remaining Useful Life y baja redundancia entre variables. De esta forma se conservaron sensores con mayor información sobre el proceso de degradación.

Resultados

Ejemplo de predicción. La probabilidad de falla estimada aumenta conforme avanza la degradación del motor, alcanzando valores cercanos a 1 en las proximidades de la falla real.



Comparación de métodos para un motor. A continuación se muestran distintas predicciones obtenidas utilizando los distintos métodos para un mismo motor.



Para comparar modelos se evaluó la capacidad de anticipar la falla a partir de la trayectoria de probabilidad estimada. Se considera que el modelo detecta una falla cuando la probabilidad predicha supera un umbral η . Se calcula la diferencia entre el ciclo estimado y el ciclo real, $\Delta T = \hat{T} - T$. A continuación se reportan métricas de error y porcentaje de detecciones exitosas.

Modelo	Det.	Error medio	RMSE	Tempranas	Exactas
UDE horizonte	66.7%	-3.38	4.40	75.0%	25.0%
UDE exacta	83.3%	-6.50	8.34	100.0%	0.0%
UDE α entrenable	66.7%	-3.63	4.49	87.5%	12.5%
UDE horizonte regularizada	41.7%	-3.80	4.54	100.0%	0.0%
NODE acumulativa	75.0%	-9.11	13.81	77.8%	22.2%
UDE combinada	66.7%	-4.38	5.47	87.5%	12.5%
Regresión Log.	16.7%	-2.50	2.55	100.0%	0.0%

Conclusiones

- El enfoque de supervivencia permite estimar probabilidades de falla directamente a partir de los datos observados.
- Los modelos dinámicos capturan la evolución temporal de la degradación.
- A pesar de la interpretabilidad del modelo NODE acumulativa, no se obtienen los mejores resultados a partir de este enfoque.
- La incorporación de conocimiento físico mediante UDEs mejora la predicción de falla de motores.
- Como trabajo futuro se propone evaluar arquitecturas más complejas y datos reales de operación.